Procena latentnog stanja pomoću varijacionog autoenkodera i Kalmanovog filtriranja

Luka Milutinović 3018/2025
Elektrotehnički fakultet, Univerzitet u Beogradu
Beograd, Srbija

Sažetak

U ovom radu predstavljen je hibridni model za procenu latentnih stanja koji kombinuje varijacioni autoenkoder (*Variational Autoencoder* – VAE) sa linearnim Kalmanovim filtrom u naučenom latentnom prostoru. Enkoder preslikava vizuelne opservacije u latentnu reprezentaciju niske dimenzionalnosti, dok Kalmanov filter obezbeđuje vremensku konzistentnost uvođenjem linearnog Gausovog apriornog modela prostora stanja.

Za modelovanje dinamike koja zavisi od okruženja uveden je mehanizam prebacivanja režima uslovljen prisustvom prepreka: u svakom vremenskom koraku GRU mreža kombinuje skup naučenih matrica prelaza stanja na osnovu trenutnog latentnog stanja i vizuelnih obeležja prepreke. Model se trenira primenom RTS izglađivanja koje obezbeđuje glatkije aposteriorne trajektorije i stabilniju optimizaciju, dok se za procenu stanja u realnom vremenu koristi kauzalni Kalmanov filter.

Predloženi model evaluiran je na simuliranom skupu podataka koji predstavlja kretanje loptice u prisustvu prepreka. Rezultati pokazuju poboljšan kvalitet rekonstrukcije, glatkije latentne trajektorije i veću preciznost višekoračne predikcije u poređenju sa referentnim modelima zasnovanim na konstantnoj brzini i GRU arhitekturi.

Ključne reči: varijacioni autoenkoder, Kalmanov filter, procena stanja, generativni modeli

1 Uvod

Estimacija latentnog stanja dinamičkog sistema na osnovu visokodimenzionalnih vizuelnih opažanja predstavlja fundamentalni problem u oblastima robotike, kontrole i kompjuterske vizije. Klasične metode u prostoru stanja, poput Kalmanovog filtra [1], omogućavaju teorijski utemeljenu procenu neizvesnosti i optimalnu linearnu estimaciju, ali zahtevaju ručno definisane modele merenja. Sa druge strane, pristupi zasnovani na dubokom učenju mogu automatski učiti bogate reprezentacije direktno iz sirovih piksela, ali obično ne uključuju eksplicitnu vremensku strukturu.

Novija istraživanja u oblasti Kalmanovih varijacionih autoenkodera (*Kalman Variational Autoencoders* – KVAE) [2] pokazuju da kombinacija VAE arhitekture sa linearnim Gausovim modelom u latentnom prostoru omogućava dobijanje interpretabilnih reprezentacija i vremenski konzistentnih predikcija. Ipak, originalni KVAE model ne uzima u obzir strukturu okruženja pri definisanju dinamike prelaza stanja, što ograničava njegovu primenu u scenarijima sa preprekama.

U ovom radu ostvareni su sledeći doprinosi:

- Predložen je KVAE proširen RTS izglađivanjem koje se primenjuje tokom treniranja radi stabilnije optimizacije i bolje propagacije gradijenata kroz mrežu za odabir režima; za procenu stanja u realnom vremenu koristi se kauzalni Kalmanov filter.
- Uveden je mehanizam prebacivanja dinamičkih režima uslovljen okruženjem: K naučenih matrica prelaza stanja kombinuje se GRU mrežom na osnovu trenutnog latentnog stanja i vizuelnih obeležja prepreke.
- Kovarijacione matrice procesnog šuma $\mathbf{Q} = q\mathbf{I}$ i šuma merenja $\mathbf{R} = r\mathbf{I}$ su fiksirane kao skalarne matrice, čime se sprečava numerička nestabilnost koja se javlja pri njihovom zajedničkom učenju sa ostalim parametrima modela.
- Uvedena je regularizacija odbijanja koja podstiče mrežu za odabir režima da promeni aktivni dinamički režim pri detekciji sudara, odnosno pri promeni smera brzine loptice usled kontakta sa preprekom. Regularizacija se primenjuje isključivo na epizode bez gravitacionog ubrzanja, jer u prisustvu gravitacije brzina se kontinualno menja i bez sudara, pa bi detektovane promene smera predstavljale lažne signale koji bi nepotrebno inicirali promenu režima.
- Model je evaluiran na kontrolisanom skupu podataka koji simulira kretanje loptice, uz poređenje sa dva referentna modela: VAE sa konstantnom brzinom i VAE zasnovanim na GRU arhitekturi (GRU-VAE).

2 Pregled literature

2.1 Kalmanov varijacioni autoenkoder

Fraccaro i saradnici [2] predložili su KVAE, koji kombinuje VAE sa linearnim Gausovim modelom u prostoru stanja (LGSSM). Enkoder VAE generiše niskodimenzionalnu reprezentaciju $\mathbf{a}_t$, dok LGSSM koristi Kalmanovo izglađivanje da proceni latentno stanje $\mathbf{z}_t$ kroz celu sekvencu. Model se trenira maksimizacijom struktuirane donje granice varijacione evidencije (ELBO).

Originalni KVAE evaluiran je na scenariju sa fiksnim okruženjem, gde se dinamika sistema ne menja između epizoda. U ovom radu razmatran je složeniji scenario u kome se raspored prepreka nasumično menja na početku svake epizode, što zahteva da model adaptira dinamiku prelaza stanja u zavisnosti od konfiguracije okruženja.

2.2 Linearni dinamički sistemi sa promenljivim režimima

Linearni dinamički sistemi sa promenljivim režimima (*Switching Linear Dynamical Systems* – SLDS) omogućavaju modelovanje nelinearne dinamike pomoću kombinacije linearnih režima rada [3]. Originalni KVAE koristi α-mrežu za ponderisanje K matrica prelaza stanja. U ovom radu taj koncept je proširen uvođenjem kontekstualnog uslovljavanja: mreža za odabir režima uzima u obzir i vizuelna obeležja prepreke, što modelu omogućava da adaptira dinamiku u zavisnosti od konfiguracije okruženja bez eksplicitnog poznavanja geometrije sudara.

2.3 Duboki modeli u prostoru stanja

Postoji veći broj radova koji kombinuju rekurentne neuralne mreže sa modelima u prostoru stanja, uključujući DVBF [4] i VRNN [5]. Ovi modeli omogućavaju učenje složenih latentnih reprezentacija i modelovanje vremenskih zavisnosti, ali često ne pružaju eksplicitnu procenu neizvesnosti ili zahtevaju aproksimacije pri inferenciji latentnog stanja.

Za razliku od navedenih pristupa, predloženi model zadržava eksplicitno izračunavanje Kalmanovog pojačanja u svakom vremenskom koraku, što omogućava interpretabilnu i teorijski utemeljenu procenu neizvesnosti. Kombinovanjem fleksibilnosti dubokih generativnih modela sa principima Kalmanovog filtriranja postiže se stabilnija optimizacija i pouzdanija procena latentnih stanja kako tokom treniranja, primenom RTS izglađivanja, tako i u realnom vremenu, primenom kauzalnog filtra.

3 Teorijska osnova

3.1 Formulacija problema

Neka je $\mathbf{x}_{1:T} = (\mathbf{x}_1, \ldots, \mathbf{x}_T)$ niz slika dimenzija $H \times W$ piksela, pri čemu svaka slika $\mathbf{x}_t$ predstavlja jedan kadar koji prikazuje loptu u pokretu. Pretpostavlja se da postoji latentno stanje $\mathbf{z}_t \in \mathbb{R}^{d_z}$ koje na fizički smislen način enkoduje poziciju i brzinu lopte u trenutku t, a koje se ne može direktno posmatrati, već samo posredno, kroz slike. Pored toga, uvodi se i latentna reprezentacija $\mathbf{a}_t \in \mathbb{R}^{d_a}$, koja predstavlja kompresovanu reprezentaciju slike $\mathbf{x}_t$ u latentnom prostoru variacionog autoenkodera. Konačno, $\mathbf{u}_t$ označava opcioni upravljački ulaz – na primer, vektor gravitacionog ubrzanja – koji može biti poznat unapred i koji utiče na dinamiku lopte.

$$p(\mathbf{x}_{1:T}, \mathbf{a}_{1:T}, \mathbf{z}_{1:T} \mid \mathbf{u}_{1:T}) = p(\mathbf{z}_0) \prod_{t=1}^{T} p_\theta(\mathbf{x}_t \mid \mathbf{a}_t)\, p(\mathbf{a}_t \mid \mathbf{z}_t)\, p(\mathbf{z}_t \mid \mathbf{z}_{t-1}, \mathbf{u}_t) \quad (1)$$

Struktura modela je ilustrovana na Slici 1: latentna stanja $\mathbf{z}_t$ formiraju Markovljev lanac kroz vreme, pri čemu iz svakog stanja $\mathbf{z}_t$ nastaje latentna reprezentacija $\mathbf{a}_t$, a iz nje se rekonstruiše opservacija $\mathbf{x}_t$ (dekoder), dok $\mathbf{a}_t$ nastaje iz $\mathbf{x}_t$ enkodovanjem (enkoder):

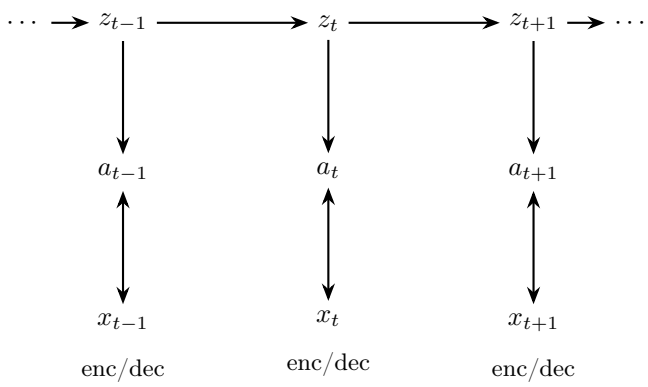

Slika 1: Grafička struktura modela. Latentna stanja slede Markovljev lanac; iz svakog z_t nastaje reprezentacija a_t, koja se enkoduje iz x_t ili dekoduje u x_t.

Centralni problemi koji se razmatraju su *filtriranje*, *izglađivanje* i *predikcija* latentnih stanja.

Filtriranje podrazumeva procenu raspodele latentnog stanja u trenutnom momentu na osnovu svih dosadašnjih merenja:

$$p(\mathbf{z}_t \mid \mathbf{a}_{1:t}, \mathbf{u}_{1:t}) \quad (2)$$

Izglađivanje koristi kompletnu sekvencu merenja – kako prošlih tako i budućih – radi preciznije retrospektivne procene stanja:

$$p(\mathbf{z}_t \mid \mathbf{a}_{1:T}, \mathbf{u}_{1:T}) \quad (3)$$

Iako izglađivanje ostvaruje manju grešku od filtriranja, nije primenljivo u realnom vremenu jer zahteva pristup celoj sekvenci unapred. U ovom radu RTS izglađivanje se koristi isključivo tokom treniranja, gde kompletna sekvenca jeste dostupna. Manja varijansa izglađene aposteriorne raspodele u poređenju sa filtriranom obezbeđuje čistiji gradijentni signal za mrežu

za odabir režima. Na taj način, svaki vremenski korak dobija informaciju i iz budućih opservacija putem povratnog prolaza izglađivača, umesto da gradijent mora da se propagira kroz ceo prolaz Kalmanovog filtra unapred kroz vreme.

Predikcija budućih stanja zahteva propagaciju raspodele kroz dinamički model bez oslanjanja na buduća merenja:

$$p(\mathbf{z}_{t+n} \mid \mathbf{a}_{1:t}, \mathbf{u}_{1:t+n}) \tag{4}$$

3.2 Varijacioni autoenkoder

3.2.1 Osnovna ideja i cilj

Varijacioni autoenkoder (VAE) [6] je generativni model koji uči kompaktnu latentnu reprezentaciju podataka. Cilj modela je aproksimacija raspodele $p_\theta(\mathbf{x})$ nad opservacijama $\mathbf{x}$ uvođenjem latentnih promenljivih $\mathbf{a}$:

$$p_\theta(\mathbf{x}) = \int p_\theta(\mathbf{x} \mid \mathbf{a})\, p(\mathbf{a})\, d\mathbf{a}. \tag{5}$$

Direktna maksimizacija log-verovatnoće $\log p_\theta(\mathbf{x})$ je neizvodljiva zbog integralnog oblika, pa se uvodi aproksimativna aposteriorna raspodela $q_\phi(\mathbf{a} \mid \mathbf{x})$, parametrizovana enkoderskom mrežom sa parametrima ϕ, koja aproksimira pravu aposteriornu $p_\theta(\mathbf{a} \mid \mathbf{x})$.

Apriorna raspodela latentnih promenljivih. Pretpostavlja se standardna Gausova raspodela:

$$p(\mathbf{a}) = \mathcal{N}(\mathbf{a};\, \mathbf{0}, \mathbf{I}), \tag{6}$$

što omogućava jednostavno računanje KL divergencije u zatvorenoj formi.

Model rekonstrukcije (dekoder). Dekoder rekonstruiše opservaciju $\mathbf{x}$ iz latentne reprezentacije $\mathbf{a}$, pri čemu se raspodela modeluje kao Gausova:

$$p_\theta(\mathbf{x} \mid \mathbf{a}) = \mathcal{N}\big(\mathbf{x};\, f_\theta(\mathbf{a}),\, \sigma_x^2 \mathbf{I}\big)\,, \tag{7}$$

gde je $f_\theta(\mathbf{a})$ izlaz dekoderske mreže sa parametrima θ, a σ_x^2 je varijansa rekonstrukcije. Maksimizacija $\log p_\theta(\mathbf{x} \mid \mathbf{a})$ ekvivalentna je minimizaciji srednje kvadratne greške između $\mathbf{x}$ i $f_\theta(\mathbf{a})$.

Aproksimativna aposteriorna raspodela (enkoder). Prava aposteriorna $p_\theta(\mathbf{a} \mid \mathbf{x})$ je neizračunljiva, pa se uvodi aproksimacija:

$$q_\phi(\mathbf{a} \mid \mathbf{x}) = \mathcal{N}\big(\mathbf{a};\, \mu_\phi(\mathbf{x}),\, \mathrm{diag}\big(\sigma_\phi^2(\mathbf{x})\big)\big)\,, \tag{8}$$

gde enkoder procenjuje srednju vrednost $\mu_\phi(\mathbf{x})$ i dijagonalnu varijansu $\sigma_\phi^2(\mathbf{x})$ po uzorku. Parametri θ i ϕ se zajednički optimizuju maksimizacijom ELBO-a, čime $q_\phi(\mathbf{a} \mid \mathbf{x})$ konvergira ka pravoj aposteriornoj raspodeli.

3.2.2 Dokaz i izvođenje ELBO granice

Koristeći Jensenovu nejednakost [7] log-verovatnoća se može donje ograničiti na sledeći način. Uvodi se aproksimativna aposteriorna $q_\phi(\mathbf{a} \mid \mathbf{x})$ i dobija se:

$$\begin{aligned}
\log p_\theta(\mathbf{x}) &= \log \int p_\theta(\mathbf{x} \mid \mathbf{a})\, p(\mathbf{a})\, d\mathbf{a} \\
&= \log \int q_\phi(\mathbf{a} \mid \mathbf{x})\, \frac{p_\theta(\mathbf{x} \mid \mathbf{a})\, p(\mathbf{a})}{q_\phi(\mathbf{a} \mid \mathbf{x})}\, d\mathbf{a} \\
&\geq \int q_\phi(\mathbf{a} \mid \mathbf{x}) \log \frac{p_\theta(\mathbf{x} \mid \mathbf{a})\, p(\mathbf{a})}{q_\phi(\mathbf{a} \mid \mathbf{x})}\, d\mathbf{a}
\end{aligned} \tag{9}$$

gde poslednja nejednakost sledi iz Jensenove nejednakosti za konkavnu funkciju log. Razdvajanjem gornjeg izraza dobija se *Evidence Lower BOund* (ELBO):

$$\begin{aligned}
&\mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}) = \\
&\underbrace{\mathbb{E}_{q_\phi(\mathbf{a}|\mathbf{x})}\left[\log p_\theta(\mathbf{x} \mid \mathbf{a})\right]}_{\text{rekonstrukcija}} - \underbrace{\mathrm{KL}\big(q_\phi(\mathbf{a} \mid \mathbf{x}) \,\|\, p(\mathbf{a})\big)}_{\text{regularizacija}}
\end{aligned} \tag{10}$$

Može se pokazati da važi:

$$\begin{aligned}
&\log p_\theta(\mathbf{x}) = \\
&\quad \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x}) + \mathrm{KL}\big(q_\phi(\mathbf{a} \mid \mathbf{x}) \,\|\, p_\theta(\mathbf{a} \mid \mathbf{x})\big) \geq \\
&\qquad \mathcal{L}_{\mathrm{ELBO}}(\theta, \phi; \mathbf{x})
\end{aligned} \tag{11}$$

jer je KL divergencija uvek nenegativna. Dakle, maksimizovanjem ELBO-a istovremeno se maksimizuje donja granica log-verovatnoće podataka (rekonstrukcija) i minimizuje se rastojanje između aproksimativne i prave posteriorne raspodele (regularizacija).

Izbor Gausovog priornog modela $p(\mathbf{a}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ i Gausovog varijacionog enkodera $q_\phi(\mathbf{a} \mid \mathbf{x}) = \mathcal{N}(\mu_\phi(\mathbf{x}), \mathrm{diag}(\sigma_\phi^2(\mathbf{x})))$ omogućava zatvorenu formu za KL divergenciju:

$$\mathrm{KL}\big(q_\phi(\mathbf{a} \mid \mathbf{x}) \,\|\, p(\mathbf{a})\big) = \frac{1}{2} \sum_{j=1}^{d_a} \big(\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1\big) \tag{12}$$

3.2.3 Trik reparametrizacije

Direktna optimizacija ELBO-a gradijentnim metodama zahteva računanje gradijenta po parametrima enkodera ϕ, što je problematično jer uzorkovanje iz $q_\phi(\mathbf{a} \mid \mathbf{x})$ uvodi stohastičnost koja prekida propagaciju gradijenata. Rešenje je *trik reparametrizacije*: umesto direktnog uzorkovanja $\mathbf{a} \sim q_\phi(\mathbf{a} \mid \mathbf{x})$, uzima se:

$$\mathbf{a} = \mu_\phi(\mathbf{x}) + \epsilon \odot \sigma_\phi(\mathbf{x}), \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \tag{13}$$

Na ovaj način, stohastičnost je izolovana u ϵ, koji ne zavisi od parametara modela, dok su μ_ϕ i σ_ϕ deterministički izlazi neuralne mreže. Gradijenti se stoga mogu propagirati normalno kroz celu mrežu.

3.3 Uopšteni ELBO za sekvencijalni model

Uopštavanjem VAE okvira na sekvencijalni slučaj, cilj je maksimizovati log-verovatnoću opservacija uslovljenu upravljačkim signalima:

$$\begin{aligned}
&\log p(\mathbf{x}_{1:T} \mid \mathbf{u}_{1:T}) = \\
&\quad \log \iint p(\mathbf{x}_{1:T}, \mathbf{a}_{1:T}, \mathbf{z}_{1:T} \mid \mathbf{u}_{1:T})\, d\mathbf{a}_{1:T}\, d\mathbf{z}_{1:T}
\end{aligned} \tag{14}$$

Uvođenjem aproksimativne raspodele $q(\mathbf{a}_{1:T}, \mathbf{z}_{1:T} \mid \mathbf{x}_{1:T}, \mathbf{u}_{1:T})$ i primenom Jensenove nejednakosti dobija se donja granica log-verovatnoće:

$$\log p(\mathbf{x}_{1:T} \mid \mathbf{u}_{1:T}) \geq \mathbb{E}_q\left[\log \frac{p(\mathbf{x}_{1:T}, \mathbf{a}_{1:T}, \mathbf{z}_{1:T} \mid \mathbf{u}_{1:T})}{q(\mathbf{a}_{1:T}, \mathbf{z}_{1:T} \mid \mathbf{x}_{1:T}, \mathbf{u}_{1:T})}\right] = \mathcal{L}_{\text{ELBO}} \quad (15)$$

Generativni model se faktoriše po Markovljevoj pretpostavci kao u (1). Za aproksimativnu raspodelu izabrana je sledeća faktorizacija:

$$q(\mathbf{a}_{1:T}, \mathbf{z}_{1:T} \mid \mathbf{x}_{1:T}, \mathbf{u}_{1:T}) = \prod_{t=1}^{T} q_\phi(\mathbf{a}_t \mid \mathbf{x}_t)\, p(\mathbf{z}_t \mid \mathbf{a}_{1:T}, \mathbf{u}_{1:T}) \quad (16)$$

gde $q_\phi(\mathbf{a}_t \mid \mathbf{x}_t)$ je VAE enkoder, a $p(\mathbf{z}_t \mid \mathbf{a}_{1:T}, \mathbf{u}_{1:T})$ je izglađena aposteriorna raspodela dobijena RTS izglađivanjem. Uvrštavanjem faktorizacije u ELBO dobija se:

$$\begin{aligned}\mathcal{L}_{\text{ELBO}} = \mathbb{E}_q\Bigg[&\underbrace{\sum_{t=1}^{T} \log p_\theta(\mathbf{x}_t \mid \mathbf{a}_t)}_{\text{rekonstrukcija}} + \underbrace{\sum_{t=1}^{T} \log p(\mathbf{a}_t \mid \mathbf{z}_t)}_{\text{inovacija}} \\ &+ \underbrace{\sum_{t=1}^{T} \log p(\mathbf{z}_t \mid \mathbf{u}_t)}_{\text{dinamički aprior}} - \underbrace{\sum_{t=1}^{T} \log q_\phi(\mathbf{a}_t \mid \mathbf{x}_t)}_{\text{entropija enkodera}} \\ &- \underbrace{\sum_{t=1}^{T} \log p(\mathbf{z}_t \mid \mathbf{a}_{1:T}, \mathbf{u}_{1:T})}_{\text{smoother posterior}}\Bigg] \quad (17)\end{aligned}$$

što direktno odgovara pet članova funkcije cilja (39): $\mathcal{L}_{\text{recon}}$, $\mathcal{L}_{\text{innov}}$, $\mathcal{L}_{\text{prior}}$, $\mathcal{L}_{\text{entr}}$ i $\mathcal{L}_{\text{post}}$.

3.4 Kalmanov filter

3.4.1 Linearni Gausovski model stanja i prostora

Kalmanov filter [1] je optimalni rekurzivni estimator stanja za linearne dinamičke sisteme sa Gausovim šumom. U nastavku se razmatra linearni Gausovski model stanja i prostora (LGSSM):

$$\mathbf{z}_t = \mathbf{A}_t \mathbf{z}_{t-1} + \mathbf{B}_t \mathbf{u}_t + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}) \quad (18)$$

$$\mathbf{a}_t = \mathbf{C}_t \mathbf{z}_t + \mathbf{v}_t, \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{R}) \quad (19)$$

gde $\mathbf{z}_t \in \mathbb{R}^{d_z}$ predstavlja *skriveno stanje* sistema (u ovom slučaju poziciju i brzinu lopte), $\mathbf{a}_t \in \mathbb{R}^{d_a}$ je *opservacija* (latentna reprezentacija slike), $\mathbf{A}_t$ je matrica tranzicije stanja, $\mathbf{C}_t$ je matrica opservacije, $\mathbf{Q}$ je kovarijansa šuma procesa, a $\mathbf{R}$ je kovarijansa šuma merenja.

Ključna osobina ovog modela je da, ako je inicijalna raspodela stanja Gausova, onda je i filtrirna raspodela Gausova u svakom trenutku t:

$$p(\mathbf{z}_t \mid \mathbf{a}_{1:t}) = \mathcal{N}(\hat{\mathbf{z}}_t, \mathbf{P}_t) \quad (20)$$

Kalmanov filter efikasno rekurzivno izračunava parametre ove raspodele.

3.4.2 Optimalnost i interpretacija

Kalmanov filter je linearni estimator koji minimizuje srednju kvadratnu grešku. Konkretno, u klasi svih linearnih estimatora, nema boljeg izbora od Kalmanovog filtera za sisteme opisane sa (18)–(19). Za linearno-Gausovske sisteme, ovaj estimator je ujedno i globalno optimalan (ne samo u klasi linearnih).

Intuitivno, Kalmanov filter balansira dva izvora informacija:

- *Predikcija*: propagacija prethodne estimacije kroz model dinamike (što daje predikovano stanje $\mathbf{z}_{t|t-1}$ i predikovanu kovarijansu $\mathbf{P}_{t|t-1}$),
- *Korekcija*: ažuriranje na osnovu novog merenja $\mathbf{a}_t$, ponderisano Kalmanovim pojačanjem $\mathbf{K}_t$ koje odražava relativnu pouzdanost predikcije i merenja.

3.4.3 Rekurzivne jednačine

Korak predikcije. Na osnovu estimirine vrednosti iz prethodnog koraka $(\hat{\mathbf{z}}_{t-1}, \mathbf{P}_{t-1})$, propagira se raspodela stanja kroz model dinamike:

$$\mathbf{z}_{t|t-1} = \mathbf{A}_t \hat{\mathbf{z}}_{t-1} + \mathbf{B}_t \mathbf{u}_t \quad (21)$$

$$\mathbf{P}_{t|t-1} = \mathbf{A}_t \mathbf{P}_{t-1} \mathbf{A}_t^\top + \mathbf{Q} \quad (22)$$

U ovom koraku se ne koristi novo merenje, već se procena stanja i kovarijansa neizvesnosti propagiraju kroz model dinamike uz dodatak kovarijanse procesnog šuma $\mathbf{Q}$.

Korak ažuriranja. Po prijemu novog merenja $\mathbf{a}_t$, vrši se ažuriranje procene stanja:

$$\mathbf{r}_t = \mathbf{a}_t - \mathbf{C}_t \mathbf{z}_{t|t-1} \quad \text{(inovacija)} \quad (23)$$

$$\mathbf{S}_t = \mathbf{C}_t \mathbf{P}_{t|t-1} \mathbf{C}_t^\top + \mathbf{R}_t \quad \text{(kovarijansa inovacije)} \quad (24)$$

$$\mathbf{K}_t = \mathbf{P}_{t|t-1} \mathbf{C}_t^\top \mathbf{S}_t^{-1} \quad \text{(Kalmanovo pojačanje)} \quad (25)$$

$$\hat{\mathbf{z}}_t = \mathbf{z}_{t|t-1} + \mathbf{K}_t \mathbf{r}_t \quad (26)$$

$$\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{C}_t) \mathbf{P}_{t|t-1} \quad (27)$$

Kalmanovo pojačanje $\mathbf{K}_t$ automatski reguliše relativni uticaj merenja u odnosu na prethodno predviđenu procenu stanja. U slučaju male vrednosti $\mathbf{R}_t$ (visoka preciznost merenja), pojačanje poprima veće vrednosti, te se procena stanja značajnije prilagođava merenju. Kada je $\mathbf{P}_{t|t-1}$ malo (visoka pouzdanost predikcije), pojačanje je manje, pa je uticaj merenja na procenu stanja redukovan.

Za ažuriranje kovarijanse koristi se *Josephova forma* [8]:

$$\mathbf{P}_t = (\mathbf{I} - \mathbf{K}_t \mathbf{C}_t) \mathbf{P}_{t|t-1} (\mathbf{I} - \mathbf{K}_t \mathbf{C}_t)^\top + \mathbf{K}_t \mathbf{R}_t \mathbf{K}_t^\top,$$

koja je numerički stabilnija od standardne forme 27, budući da osigurava pozitivnu semidefinitnost kovarijacione matrice čak i u prisustvu numeričkih grešaka.

3.4.4 Rekurzivna struktura i prednosti

Fundamentalna prednost Kalmanovog filtra proizilazi iz njegove *rekurzivne strukture*: za izračunavanje procene stanja $(\hat{\mathbf{z}}_t, \mathbf{P}_t)$ potrebno je samo poznavanje prethodne procene $(\hat{\mathbf{z}}_{t-1}, \mathbf{P}_{t-1})$ i novog merenja $\mathbf{a}_t$ – nije neophodno čuvati niti ponovo procesirati sva prethodna merenja $\mathbf{a}_{1:t-1}$. Ova karakteristika čini Kalmanov filter posebno pogodnim za primene u realnom vremenu sa ograničenim memorijskim zahtevima.

3.4.5 RTS izglađivanje

Rauch–Tung–Striebel (RTS) izglađivač [9] proširuje Kalmanov filter tako što, nakon završenog prolaska unapred, izvršava prolazak unazad kroz sekvencu i revidira procene stanja korišćenjem informacija iz budućih opservacija. Na taj način dobija se izglađena aposteriorna raspodela:

$$p(\mathbf{z}_t \mid \mathbf{a}_{1:T}) = \mathcal{N}(\hat{\mathbf{z}}_t^s, \mathbf{P}_t^s) \tag{28}$$

Prolaz unazad. Počevši od poslednjeg vremenskog koraka T, gde važi $\hat{\mathbf{z}}_T^s = \hat{\mathbf{z}}_T$ i $\mathbf{P}_T^s = \mathbf{P}_T$, rekurzivno se izračunava:

$$\mathbf{G}_t = \mathbf{P}_t \mathbf{A}_{t+1}^\top \mathbf{P}_{t+1|t}^{-1} \quad \text{(pojačanje izglađivača)} \tag{29}$$

$$\hat{\mathbf{z}}_t^s = \hat{\mathbf{z}}_t + \mathbf{G}_t \left(\hat{\mathbf{z}}_{t+1}^s - \mathbf{z}_{t+1|t}\right) \tag{30}$$

$$\mathbf{P}_t^s = \mathbf{P}_t + \mathbf{G}_t \left(\mathbf{P}_{t+1}^s - \mathbf{P}_{t+1|t}\right) \mathbf{G}_t^\top \tag{31}$$

gde superskript s označava izglađene veličine, a $\mathbf{G}_t$ je pojačanje izglađivača koje određuje koliko buduće informacije koriguju trenutnu procenu.

RTS izglađivač je optimalan u smislu minimalne srednje kvadratne greške za linearno-Gausovske sisteme i ostvaruje preciznije procene od kauzalnog filtra po cenu dodatnog prolaska unazad. Kako zahteva pristup celoj sekvenci unapred, nije primenljiv u realnom vremenu, ali je pogodan za upotrebu tokom treniranja gde je kompletna sekvenca uvek dostupna.

4 Predloženi model

Predloženi model kombinuje varijacioni autoenkoder, linearno-Gausovski model stanja i prostora i mehanizam prebacivanja dinamičkih režima uslovljene preprekom. U nastavku su opisane sve komponente sistema.

4.1 VAE enkoder i dekoder

Konvolucioni enkoder $q_\phi(\mathbf{a}_t \mid \mathbf{x}_t)$ obrađuje svaki kadar nezavisno i preslikava ga u Gausovu raspodelu u latentnom prostoru dimenzije d_a:

$$q_\phi(\mathbf{a}_t \mid \mathbf{x}_t) = \mathcal{N}\big(\mu_t,\, \mathrm{diag}(\sigma_t^2)\big) \tag{32}$$

gde su $\mu_t = f_\phi^\mu(\mathbf{x}_t) \in \mathbb{R}^{d_a}$ i $\sigma_t^2 = f_\phi^\sigma(\mathbf{x}_t) \in \mathbb{R}_{>0}^{d_a}$ izlazi dve odvojene glave enkoderske mreže sa zajedničkim parametrima ϕ. Latentna reprezentacija se uzorkuje primenom trika reparametrizacije opisanog u odeljku 3.2.3:

$$\mathbf{a}_t = \mu_t + \epsilon_t \odot \sigma_t, \quad \epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \tag{33}$$

Dekoder $p_\theta(\mathbf{x}_t \mid \mathbf{a}_t)$ je simetričan konvolucioni dekoder koji primenjuje transpozicione konvolucije za uzorkovanje naviše.

Pored enkodera loptice, uvodi se enkoder prepreke koji preslikava statičku sliku prepreke u kontekstualni vektor $\mathbf{h}_{\text{obs}} \in \mathbb{R}^{d_{\text{obs}}}$. Kako mreža za odabir režima nema direktan supervizijski signal i uči se u potpunosti iz sirovog video signala, enkoder prepreke deli konvolucione slojeve sa enkoderom loptice. Na taj način obeležja prepreke i loptice žive u sličnom latentnom prostoru, što olakšava konvergenciju mreže za odabir režima. Gradijenti se tokom treniranja propagiraju isključivo kroz enkoder loptice – konvolucioni slojevi su zamrznuti u odnosu na enkoder prepreke.

4.2 Linearno-Gausovski model stanja i prostora

Latentno stanje $\mathbf{z}_t \in \mathbb{R}^{d_z}$ modeluje se linearno-Gausovskim modelom koji odgovara formulaciji opisanoj u odeljku 3.4. Sistem je definisan sledećim jednačinama tranzicije i opservacije:

$$\mathbf{z}_t = \mathbf{A}_t \mathbf{z}_{t-1} + \mathbf{B}_t \mathbf{u}_t + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}) \tag{34}$$

$$\mathbf{a}_t = \mathbf{C}_t \mathbf{z}_t + \mathbf{v}_t, \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{R}) \tag{35}$$

gde $\mathbf{A}_t \in \mathbb{R}^{d_z \times d_z}$ je matrica tranzicije stanja, $\mathbf{B}_t \in \mathbb{R}^{d_z \times d_u}$ je matrica upravljanja, $\mathbf{C}_t \in \mathbb{R}^{d_a \times d_z}$ je matrica opservacije, $\mathbf{Q} = q\mathbf{I}$ je fiksirana kovarijansa šuma procesa, a $\mathbf{R} = r\mathbf{I}$ je fiksirana kovarijansa šuma merenja. Eksperimentalno je utvrđeno da zajedničko učenje $\mathbf{Q}$ i $\mathbf{R}$ sa ostalim parametrima modela dovodi do numeričke nestabilnosti u ranim fazama treniranja, pa su obe matrice fiksirane kao skalarne.

Ključna razlika u odnosu na standardni LGSSM iz odeljka 3.4 je u tome što matrice $\mathbf{A}_t$ i $\mathbf{C}_t$ nisu fiksne već vremenski promenljive i zavisne od konteksta – njihova konstrukcija opisana je u odeljku 4.3.

4.3 Dinamika uslovljena preprekom za izbor režima

Kako bi se modelovala dinamika zavisna od okruženja – na primer, odbijanje lopte od prepreke – matrice tranzicije i opservacije predstavljene su kao težinske kombinacije K naučenih matrica:

$$\mathbf{A}_t = \sum_{i=1}^{K} \alpha_t^{(i)} \mathbf{A}^{(i)}, \quad \mathbf{C}_t = \sum_{i=1}^{K} \alpha_t^{(i)} \mathbf{C}^{(i)} \tag{36}$$

gde svaki par $(\mathbf{A}^{(i)}, \mathbf{C}^{(i)})$ predstavlja jedan linearni dinamički režim. Vektor težina α_t dobija se kao izlaz GRU-bazirane mreže za odabir režima, uslovljene prethodnom opservacijom u latentnom prostoru, kontekstualnim vektorom prepreke i opcionalnim upravljačkim ulazom:

$$\alpha_t = \mathrm{softmax}(\mathbf{W}\,\mathrm{GRU}([\mathbf{a}_{t-1};\, \mathbf{h}_{\mathrm{obs}};\, \mathbf{u}_t],\, \mathbf{h}_{t-1})) \tag{37}$$

gde $\mathbf{h}_{t-1}$ označava skriveno stanje GRU-a iz prethodnog koraka. Na ovaj način model uči da odabere odgovarajući linearni režim na osnovu prethodne pozicije lopte i konfiguracije prepreke, bez eksplicitnog poznavanja geometrije sudara. Kontinuirana kombinacija matrica umesto diskretnog prebacivanja čuva diferencijabilnost celog sistema, što omogućava zajedničko treniranje svih komponenti modela.

Kako mreža za odabir režima ne prima direktan supervizijski signal, uvedena je regularizacija odbijanja koja podstiče promenu aktivnog režima u trenutku detekcije sudara. Sudar se detektuje kao nagli obrt smera kretanja u latentnom prostoru, mereno kosinusnom udaljenošću uzastopnih inkremenata $\Delta\mathbf{a}_t = \mathbf{a}_t - \mathbf{a}_{t-1}$. U tim trenucima gubitak kažnjava visoku kosinusnu sličnost uzastopnih vektora α_t, čime se podstiče diverzitet dinamičkih režima pri sudaru.

4.4 Kalmanov filter u latentnom prostoru

Nakon što su konstruisane matrice $\mathbf{A}_t$ i $\mathbf{C}_t$ i dobijen izlaz enkodera (μ_t, σ_t^2), pokreće se Kalmanov filter opisan u odeljku 3.4. Kao merenje koristi se uzorkovana latentna reprezentacija dobijena trikom reparametrizacije tokom treniranja, dok se tokom evaluacije koristi samo srednja vrednost enkodera $\mathbf{a}_t = \mu_t$. Nakon prolaza unapred, RTS izglađivač izvršava prolaz unazad i daje izglađenu aposteriornu raspodelu:

$$p(\mathbf{z}_t \mid \mathbf{a}_{1:T}) = \mathcal{N}(\hat{\mathbf{z}}_t^s, \mathbf{P}_t^s) \tag{38}$$

Ceo prolaz kroz filter i izglađivač je diferencijabilan i implementiran u matričnim operacijama, što omogućava propagaciju gradijenata kroz obe komponente tokom treniranja.

4.5 Funkcija cilja

Model se trenira maksimizacijom sekvencijalnog ELBO-a izvedenog u odeljku 3.3. Ciljna funkcija po sekvenci ima oblik:

$$\begin{aligned}\mathcal{F} = &\log p_\theta(\mathbf{x} \mid \mathbf{a}) + \log p(\mathbf{a} \mid \mathbf{z}) + \log p(\mathbf{z} \mid \mathbf{u}) \\ &- \log q_\phi(\mathbf{a} \mid \mathbf{x}) - \log p(\mathbf{z} \mid \mathbf{a}, \mathbf{u})\end{aligned} \tag{39}$$

uz dodatnu regularizaciju odbijanja $\mathcal{L}_{\mathrm{bounce}}$. Ukupni optimizacioni cilj predstavlja očekivanje po aproksimativnoj aposteriornoj raspodeli, koje se u praksi aproksimira jednim Monte Karlo uzorkom po sekvenci. Model se trenira maksimizacijom ovog ELBO-a, odnosno ekvivalentno minimizacijom odgovarajuće negativne funkcije cilja.

Ukupni gubitak definiše se kao ponderisana suma komponenti:

$$\begin{aligned}\mathcal{L} = &\lambda_r \mathcal{L}_{\mathrm{recon}} + \lambda_i \mathcal{L}_{\mathrm{innov}} + \lambda_p \mathcal{L}_{\mathrm{prior}} \\ &- \lambda_e \mathcal{L}_{\mathrm{entr}} - \lambda_s \mathcal{L}_{\mathrm{post}} + \lambda_b \mathcal{L}_{\mathrm{bounce}}\end{aligned} \tag{40}$$

Gubitak rekonstrukcije. Meri se binarna unakrsna entropija između ulaznog kadra i rekonstrukcije dobijene iz izglađene latentne reprezentacije $\hat{\mathbf{a}}_t^s = \mathbf{C}_t \hat{\mathbf{z}}_t^s$:

$$\mathcal{L}_{\mathrm{recon}} = -\frac{1}{T} \sum_{t=1}^{T} \log p_\theta(\mathbf{x}_t \mid \hat{\mathbf{a}}_t^s) \tag{41}$$

Ovaj član odgovara terminu $\sum_t \log p_\theta(\mathbf{x}_t \mid \mathbf{a}_t)$ iz ELBO-a pod Bernulijevom pretpostavkom dekodera, pri čemu se umesto uzorkovanog $\mathbf{a}_t$ koristi deterministička rekonstrukcija iz izglađenog stanja.

Inovacioni gubitak. Meri neusaglašenost enkodovanih reprezentacija sa izglađenim stanjima:

$$\mathcal{L}_{\mathrm{innov}} = -\frac{1}{T} \sum_{t=1}^{T} \log \mathcal{N}(\mathbf{a}_t;\, \hat{\mathbf{a}}_t^s,\, \mathbf{R}) \tag{42}$$

Ovaj član odgovara terminu $\sum_t \log p(\mathbf{a}_t \mid \mathbf{z}_t)$ iz ELBO-a i podstiče enkoder da generiše reprezentacije konzistentne sa izglađenim stanjima.

Dinamički aprior. Kažnjava odstupanje izglađenih stanja od predikcije modela dinamike:

$$\mathcal{L}_{\mathrm{prior}} = -\frac{1}{T-1} \sum_{t=1}^{T-1} \log \mathcal{N}(\hat{\mathbf{z}}_{t+1}^s;\, \hat{\mathbf{z}}_{t+1|t},\, \mathbf{Q}) \tag{43}$$

Ovaj član odgovara terminu $\sum_t \log p(\mathbf{z}_t \mid \mathbf{u}_t)$ iz ELBO-a i obezbeđuje da izglađene trajektorije ostanu fizički smislene u smislu naučenog modela dinamike.

Entropija enkodera. Sprečava kolaps varijacione raspodele i podstiče očuvanje disperzije u latentnom prostoru:

$$\mathcal{L}_{\mathrm{entr}} = \frac{1}{T} \sum_{t=1}^{T} \log q_\phi(\mathbf{a}_t \mid \mathbf{x}_t) \tag{44}$$

Ovaj član odgovara terminu $-\sum_t \log q_\phi(\mathbf{a}_t \mid \mathbf{x}_t)$ iz ELBO-a.

Smoother posterior. Maksimizuje log-verovatnoću uzorkovanih latentnih stanja pod izglađenom aposteriornom raspodelom:

$$\mathcal{L}_{\text{post}} = \frac{1}{T} \sum_{t=1}^{T} \log p(\mathbf{z}_t \mid \mathbf{a}_{1:T}, \mathbf{u}_{1:T}) \tag{45}$$

Ovaj član odgovara terminu $-\sum_t \log p(\mathbf{z}_t \mid \mathbf{a}_{1:T}, \mathbf{u}_{1:T})$ iz ELBO-a. Maksimizacijom ovog člana model se podstiče da uzorkuje stanja koja su konzistentna sa izglađenom aposteriornom raspodelom, čime se smanjuje oslanjanje isključivo na trenutne opservacije i povećava doprinos dinamičkog modela u formiranju latentnih stanja.

Regularizacija odbijanja. Kako mreža za odabir režima nema direktan supervizijski signal, uvodi se regularizacija koja podstiče promenu aktivnog režima pri sudaru loptice sa preprekom. Sudar se detektuje kao nagla promena smera kretanja u latentnom prostoru, merena kosinusnom udaljenošću uzastopnih inkremenata $\Delta\mathbf{a}_t = \mathbf{a}_t - \mathbf{a}_{t-1}$. U tim trenucima gubitak kažnjava visoku sličnost uzastopnih vektora težina mešanja α_t, ponderisanu jačinom detektovanog sudara. Regularizacija se primenjuje isključivo na epizode bez gravitacionog ubrzanja – u prisustvu gravitacije brzina se kontinualno menja čak i bez sudara, pa bi detektovane promene smera bile lažni signal koji bi nepotrebno forsirao promenu režima i u slučajevima kada bi mreža trebalo da ostane u istom.

Raspored treniranja. Treniranje je organizovano u šest faza. U prvoj fazi (*warmup*) gradijenti mreže za odabir režima su zamrznuti kako bi se ostatak modela stabilizovao pre nego što ona počne da uči. Druga faza uvodi kompletno treniranje svih komponenti, a treća fino podešavanje sa smanjenom stopom učenja i resetovanim optimizatorom. Četvrta i peta faza postepeno uvode maskiranje opservacija – najpre nasumično, zatim sa progresivno rastućim brojem maskiranih koraka – čime model uči koherentne višekoračne predikcije. U završnoj fazi ostale komponente su zamrznute, dok se trenira isključivo dekoder.

5 Eksperimenti i rezultati

5.1 Skup podataka

Evaluacija je izvedena na sintetičkom skupu podataka koji simulira kretanje lopte u zatvorenom prostoru. Svaka epizoda sadrži sekvencu od $T = 40$ frejmova dimenzija 32×32 piksela, pri čemu su slike binarne – lopta i prepreke prikazani su belim pikselima na crnoj pozadini. Lopta se kreće konstantnom brzinom i elastično odbija od zidova i pravougaonih prepreka koje se nasumično raspoređuju na početku svake epizode i ostaju nepomične tokom cele sekvence. Simulator takođe omogućava uključivanje gravitacije, čime se uvodi dodatna sila koja menja putanju lopte i povećava kompleksnost predikcije. U skupu podataka polovina epizoda sadrži gravitaciono ubrzanje, a polovina ne, čime se obezbeđuje uravnotežena zastupljenost oba scenarija. Skup podataka sadrži 16000 epizoda za trening, 1000 za validaciju i 1000 za testiranje.

5.2 Referentni modeli

Predloženi model upoređen je sa dva referentna modela koji različito modeluju dinamiku:

- **CV-VAE**: Referentni model konstantne brzine. Sledeće latentno stanje predviđa se kao $\hat{\mathbf{a}}_{t+1} = \mathbf{a}_t + (\mathbf{a}_t - \mathbf{a}_{t-1})$. Model ne sadrži naučene parametre dinamike.
- **GRU-VAE**: GRU mreža koja prima enkodovanu opservaciju $\mathbf{a}_t$, kontekstualni vektor prepreke $\mathbf{h}_{\text{obs}}$ i upravljački signal $\mathbf{u}_t$ kao ulaz i predviđa $\hat{\mathbf{a}}_{t+1}$. Model uči dinamiku bez eksplicitne kvantifikacije nesigurnosti.

5.3 Detalji implementacije

Svi modeli su implementirani u biblioteci PyTorch i trenirani korišćenjem optimizatora AdamW sa stopom učenja $\text{lr} = 5 \cdot 10^{-3}$ i kosinusnim smanjenjenjem stope učenja. Latentne dimenzije su postavljene na $d_a = 2$ i $d_z = 4$, pri čemu se prvi latentni prostor može interpretirati kao pozicioni prostor, dok drugi obuhvata proširenu reprezentaciju stanja koja uključuje i brzinske komponente. Koriste se $K = 3$ matrice prelaza, pri čemu se očekuje da model nauči da ih asocira sa slobodnim kretanjem lopte, odbijanjem od vertikalnih i odbijanjem od horizontalnih granica prostora.

5.4 Rezultati

5.4.1 Kvantitativna evaluacija

Slika 2 prikazuje MSE predikcije u zavisnosti od horizonta n za sva tri modela, odvojeno za epizode sa i bez gravitacionog ubrzanja. KVAE konzistentno ostvaruje najnižu grešku, pri čemu se prednost povećava sa dužinom horizonta. U epizodama bez gravitacije, CV-VAE postiže relativno nižu grešku u odnosu na slučaj sa gravitacijom, što je u skladu sa njegovom pretpostavkom približno linearne dinamike sa

konstantnom brzinom između interakcija, pri čemu se nelinearnosti javljaju diskretno usled sudara sa preprekama i zidovima. U prisustvu gravitacije, međutim, ova pretpostavka više ne važi, te greška CV-VAE modela značajno raste sa horizontom predikcije. Nasuprot tome, GRU-VAE pokazuje sličan trend u oba scenarija, ali uz konzistentno višu grešku u odnosu na KVAE. Konačno, primena RTS izglađivača u okviru KVAE dodatno smanjuje grešku, dajući najbolje ukupne rezultate zahvaljujući korišćenju informacija iz cele sekvence.

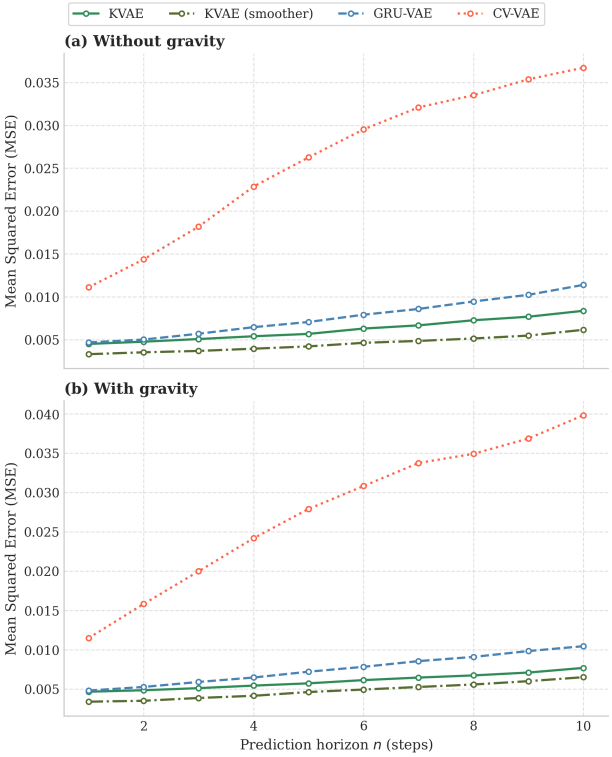

Slika 2: MSE predikcije u zavisnosti od horizonta n.

5.4.2 Naučeni latentni prostor

Slika 3 prikazuje strukturu naučenog latentnog prostora **a**. Da bi se vizualizovalo kako enkoder mapira pozicije lopte, generisana je sintetička sekvenca koja sistematično pokriva sve moguće pozicije lopte na ekranu. Prostorna koherentnost rasporeda tačaka ukazuje da enkoder uči topološki konzistentnu reprezentaciju – susedne pozicije u pikselnom prostoru preslikavaju se u susedne tačke u latentnom prostoru.

5.4.3 Naučena dinamika i mreža za odabir režima

Slika 4 i Slika 5 prikazuju težinske koeficijente za izbor režima α_t kroz vreme za epizode sa i bez preprека. U oba slučaja jedan režim dominira tokom većeg dela trajektorije, dok se ostali aktiviraju kratkotrajno u trenucima sudara sa zidovima ili preprekama.

Ovo sugeriše da model koristi jedan dominantan režim kao globalnu aproksimaciju dinamike, dok ostale koristi kao lokalne korekcije pri nelinearnim interakcijama. Promene koeficijenata su dosledno usklađene

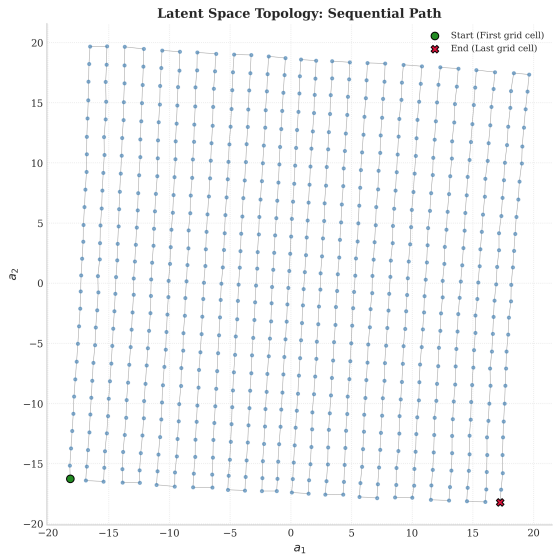

Slika 3: Vizualizacija naučenog latentnog prostora **a**.

sa sudarima, što ukazuje da mreža za odabir režima uspešno prepoznaje relevantne događaje u sistemu.

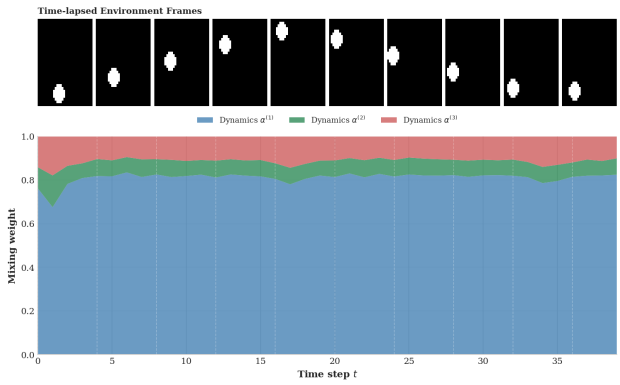

Slika 4: Težinski koeficijenti $\alpha_t^{(1)}, \alpha_t^{(2)}, \alpha_t^{(3)}$ tokom vremena u slučaju epizode bez prepreka.

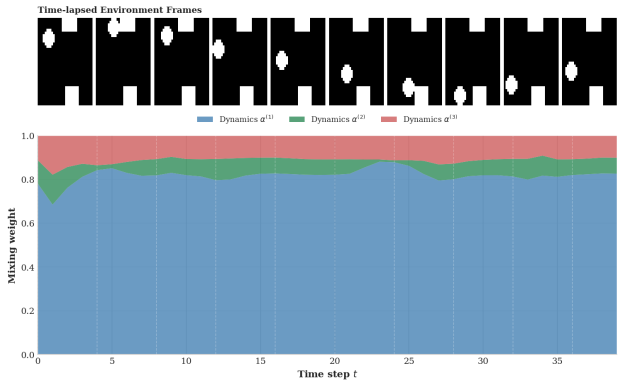

Slika 5: Težinski koeficijenti $\alpha_t^{(1)}, \alpha_t^{(2)}, \alpha_t^{(3)}$ tokom vremena u slučaju epizode sa preprekama.

5.4.4 Kvantifikacija nesigurnosti i imputacija

Jedna od ključnih prednosti KVAE modela u odnosu na referentne modele je eksplicitna kvantifikaci-

ja nesigurnosti kroz kovarijacionu matricu $\mathbf{P}_t$. Slika 6 prikazuje dijagonalu $\mathbf{P}_t$ kroz vreme za epizodu u kojoj su frejmovi iz sredine sekvence maskirani, odvojeno za kauzalni filter i RTS izglađivač. U oba slučaja varijansa raste tokom maskiranih koraka i opada čim stigne nova opservacija, što odražava povećanu neizvesnost u odsustvu merenja. RTS izglađivač ostvaruje manju varijansu jer koristi informacije iz cele sekvence.

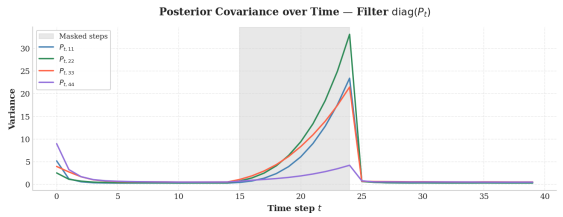

(a) Kalmanov filter

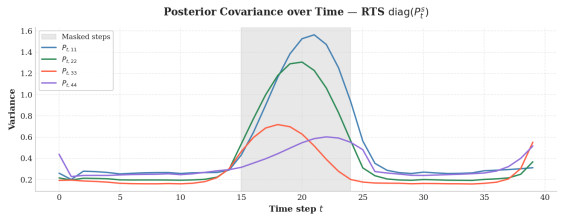

(b) RTS izglađivač

Slika 6: Dijagonala kovarijanse $\mathbf{P}_t$ kroz vreme. Siva oblast označava maskirane korake. Primećuje se značajno manja varijanasa kod RTS izglađivača (dole) usled korišćenja informacija iz budućnosti.

Slika 7 poredi trajektorije u latentnom prostoru za istu epizodu sa maskiranjem. Kauzalni filter divergira tokom maskiranih koraka jer nema pristup budućim opservacijama, dok RTS izglađivač koriguje trajektoriju koristeći ostatak sekvence, što rezultuje znatno manjim odstupanjem od stvarne putanje. Dodatno, ograničena rezolucija ulaznih slika uvodi izražen kvantizacioni efekat u posmatranim trajektorijama. Kada se objekat kreće sa neujednačenim komponentama brzine (npr. dominantno u jednom pravcu uz sporiju komponentu u drugom), diskretna priroda piksela dovodi do toga da se njegova projekcija kroz više uzastopnih frejmova menja pretežno duž jedne ose, dok se komponenta kretanja u drugom pravcu ispoljava tek sporadično, kroz nagle pomake. Posledično, enkodovane reprezentacije μ_t odražavaju ove diskretne prelaze kao veštačke diskontinuitete u latentnom prostoru. Uvođenjem linearnog Gausovog dinamičkog apriora, Kalmanov filter i RTS izglađivač implicitno uvode vremensku glatkoću u procenu.

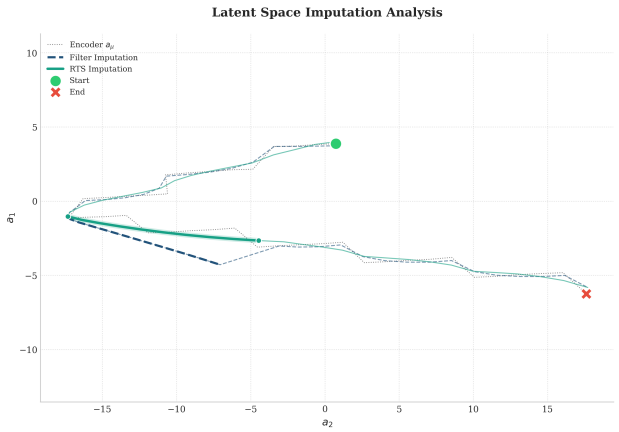

Slika 7: Trajektorije u latentnom prostoru $\mathbf{a}$ za epizodu sa maskiranjem.

6 Zaključak

U ovom radu predložen je hibridni model za procenu latentnih stanja koji kombinuje varijacioni autoenkoder sa linearno-Gausovskim modelom prostora stanja u naučenom latentnom prostoru. Ključni doprinos u odnosu na originalni KVAE model je uvođenje dinamike sa promenljivim režimima uslovljene okruženjem, gde mreža za odabir režima kombinuje K naučenih matrica prelaza na osnovu trenutnog latentnog stanja i vizuelnih obeležja prepreke. Pored toga, RTS izglađivanje se primenjuje tokom treniranja radi stabilnije optimizacije i bolje propagacije gradijenata, dok kauzalni Kalmanov filter omogućava procenu stanja u realnom vremenu.

Eksperimentalni rezultati na simuliranom skupu podataka pokazuju da predloženi KVAE model dosledno nadmašuje referentne pristupe u višekoračnoj predikciji, pri čemu se prednost povećava sa horizontom. KVAE ostvaruje najnižu grešku u oba razmatrana scenarija, dok CV-VAE pokazuje relativno nižu grešku u epizodama bez gravitacije, ali višu grešku u prisustvu gravitacije. GRU-VAE pokazuje sličan trend u oba scenarija, ali uz konzistentno višu grešku u odnosu na KVAE. Konačno, primena RTS izglađivača dodatno poboljšava performanse KVAE modela i daje najbolje ukupne rezultate.

Nekoliko pravaca ostaje otvoreno za buduća istraživanja. Evaluacija na složenijim scenarijima sa većim brojem prepreka i višim rezolucijama slika bila bi prirodan sledeći korak, jer bi viša rezolucija smanjila diskontinuitete u enkodovanim trajektorijama koji nastaju usled grube pikselizacije. Pored toga, trenutna implementacija koristi fiksirane kovarijacione matrice $\mathbf{Q}$ i $\mathbf{R}$, čije bi adaptivno učenje potencijalno poboljšalo performanse uz odgovarajuću regularizaciju. Konačno, kontekstualni vektor prepreke trenutno se dobija iz slike okruženja, ali prirodna alternativa bila bi zamena vizuelnog enkodera prepreke merenjima rastojanja poput onih koje pruža LiDAR senzor – na osnovu izmerenih rastojanja do zidova i prepreka model bi mogao direktno da uslovljava dinamiku bez oslanjanja na vizuelnu reprezentaciju okruženja.

Literatura

[1] R. E. Kalman, *A new approach to linear filtering and prediction problems*, Journal of Basic Engineering, 1960.

[2] M. Fraccaro, S. Kamronn, U. Paquet, and O. Winther, *A Disentangled Recognition and Nonlinear Dynamics Model for Unsupervised Learning*, 2017.

[3] Z. Ghahramani and G. E. Hinton, *Variational Learning for Switching State-Space Models*, *Neural Computation*, vol. 12, no. 4, pp. 831–864, 2000.

[4] M. Karl, M. Soelch, J. Bayer, and P. van der Smagt, *Deep variational bayes filters: Unsupervised learning of state space models from raw data*, in *International Conference on Learning Representations*, 2014.

[5] J. Chung, K. Kastner, L. Dinh, K. Goel, A. Courville, and Y. Bengio, *A Recurrent Latent Variable Model for Sequential Data*, in *Advances in Neural Information Processing Systems*, 2015.

[6] D. P. Kingma and M. Welling, *Auto-Encoding Variational Bayes*, in *International Conference on Learning Representations*, 2014.

[7] J. L. Jensen, *Sur les fonctions convexes et les inégalités entre les valeurs moyennes*, *Acta Mathematica*1906.

[8] P. D. Joseph and R. S. Bucy, *Filtering for Stochastic Processes with Applications to Guidance*, 1968.

[9] H. E. Rauch, F. Tung, and C. T. Striebel, *Maximum likelihood estimates of linear dynamic systems*, AIAA Journal, 1965.